

Estimación de Incertidumbre en Proyecciones de Impacto Climático mediante Fusión de Métodos Bayesianos y Simulación de Monte Carlo: Una Revisión Sistemática

Bryan Cutipa Carcasi

*Facultad de Ingeniería Estadística e Informática
Universidad Nacional del Altiplano
Puno, Perú*

Abstract—Las proyecciones de impacto del cambio climático enfrentan incertidumbres significativas derivadas de múltiples fuentes, incluyendo modelos climáticos globales (GCMs), escenarios de emisiones, parámetros de modelos sectoriales y variabilidad natural del sistema climático. Para abordar estas incertidumbres, la fusión de métodos bayesianos con simulación de Monte Carlo ha emergido como un enfoque prometedor. Esta revisión sistemática analiza la literatura científica global sobre la aplicación integrada de inferencia bayesiana y simulación de Monte Carlo en estudios de impacto climático, cubriendo publicaciones desde 2007 hasta 2025 recuperadas de la base de datos Scopus. Los datos fueron procesados mediante análisis estadístico y las palabras clave fueron mapeadas con VOSviewer. Los resultados muestran que los estudios se concentran principalmente en los sectores de recursos hídricos, agricultura, salud ambiental y gestión de ecosistemas. La mayoría de los estudios aplican simulación de Monte Carlo estándar (87%), mientras que solo una minoría (13%) implementa acoplamiento fuerte con métodos bayesianos mediante MCMC. Las métricas de incertidumbre más comunes son intervalos de confianza (95%), distribuciones de probabilidad y desviación estándar. La revisión destaca que la incertidumbre de los modelos climáticos globales constituye la fuente principal de incertidumbre en la mayoría de los estudios. Estos hallazgos proporcionan a investigadores, gestores ambientales y formuladores de políticas una perspectiva global para guiar futuras estrategias de evaluación de impacto climático bajo incertidumbre.

Index Terms—Métodos bayesianos, simulación de Monte Carlo, cambio climático, evaluación de impacto, incertidumbre, MCMC

I. INTRODUCCIÓN

Las proyecciones de impacto climático son fundamentales para la planificación de estrategias de adaptación y mitigación, pero están inherentemente sujetas a múltiples fuentes de incertidumbre [1].

La incertidumbre en las proyecciones climáticas surge de diversas fuentes: (i) la variabilidad natural del sistema climático, (ii) la incertidumbre en escenarios de emisiones futuras, (iii) las limitaciones de los modelos climáticos globales (GCMs), y (iv) los errores en los modelos de impacto sectorial [2]. Esta cascada de incertidumbres se propaga a través de la cadena de modelación, amplificándose en cada etapa [3].

Durante las últimas décadas, dos enfoques metodológicos han ganado prominencia para abordar estas incertidumbres: la inferencia bayesiana y la simulación de Monte Carlo. Los métodos bayesianos permiten la actualización formal de creencias sobre parámetros desconocidos mediante el teorema de Bayes, integrando información previa con nuevas evidencias observacionales [4]. Por su parte, la simulación de Monte Carlo permite la exploración sistemática del espacio de incertidumbre mediante muestreo aleatorio repetido [5].

La fusión de ambos enfoques ofrece ventajas significativas: los métodos bayesianos proporcionan un marco teórico riguroso para la cuantificación de incertidumbre, mientras que Monte Carlo ofrece herramientas computacionales eficientes para la propagación de incertidumbre en sistemas complejos [6]. Sin embargo, la aplicación integrada de estos métodos en estudios de impacto climático permanece heterogénea y fragmentada en la literatura.

A pesar del creciente interés en la cuantificación de incertidumbre climática, existe una carencia de revisiones sistemáticas que sinteticen cómo se están fusionando estos métodos en la práctica. Las preguntas clave que permanecen sin respuesta incluyen: ¿Cuáles sectores están adoptando activamente estos métodos? ¿Qué nivel de acoplamiento entre métodos bayesianos y Monte Carlo se está implementando? ¿Cuáles son las principales fuentes de incertidumbre identificadas? ¿Qué métricas se utilizan para reportar incertidumbre?

El objetivo de esta investigación es realizar una revisión sistemática de la literatura global sobre la aplicación fusionada de métodos bayesianos y simulación de Monte Carlo en proyecciones de impacto climático, identificando tendencias metodológicas, sectores de aplicación, fuentes dominantes de incertidumbre y brechas de conocimiento.

El resto de este artículo se organiza de la siguiente manera. La Sección II describe los materiales y métodos, incluyendo la estrategia de búsqueda bibliográfica, procesamiento de datos y análisis de palabras clave. La Sección III presenta los resultados y discusión, destacando tendencias globales, sectores clave y los enfoques metodológicos más frecuentemente aplicados. La Sección IV proporciona las principales

conclusiones y delinea recomendaciones para investigación futura y la adopción práctica de estos métodos en la evaluación de impactos climáticos.

II. MATERIALES Y MÉTODOS

A. Estrategia de búsqueda bibliográfica

La bibliografía consultada abarca desde 2007 hasta febrero de 2025. Se aplicaron operadores booleanos utilizando los siguientes términos: “Bayesian”, “Monte Carlo”, “climate change”, “impact assessment” y “uncertainty”. Toda la investigación se realizó mediante búsqueda en la base de datos Scopus, debido a su capacidad para compilar textos de acceso abierto después de una rigurosa revisión por pares [7].

Se aplicó la siguiente cadena de búsqueda:

```
(TITLE-ABS-KEY ( ( ( "Bayesian" OR "Bayesian inference" OR "Bayesian Model Averaging" ) AND ( "Monte Carlo" OR "MCMC" OR "Markov Chain Monte Carlo" ) AND ( "climate impact*" OR "climate projection*" OR "climate change impact*" ) AND ( "uncertainty" OR "uncertainty quantification" ) ) ) ) AND ( LIMIT-TO ( DOCTYPE , "ar" ) )
```

Se encontraron inicialmente 156 artículos científicos, de los cuales 19 estudios fueron seleccionados y utilizados para este estudio después de aplicar criterios de inclusión y exclusión (Fig. 1).

B. Criterios de inclusión y exclusión

Se consideraron publicaciones desde 2007 hasta febrero de 2025 en todos los idiomas. Se revisaron títulos, resúmenes, metodología y resultados principales para seleccionar artículos de interés. El alcance geográfico fue mundial. Se excluyeron capítulos de libros, ponencias de conferencias y cartas al editor. También se excluyó la literatura gris porque no pasó revisión por pares [8]. Además, no se tomaron en cuenta estudios no concluyentes y duplicados (Fig. 2).

Los criterios específicos de inclusión fueron:

- Estudios que apliquen explícitamente métodos bayesianos O simulación de Monte Carlo en evaluación de impacto climático
- Estudios que cuantifiquen incertidumbre de forma explícita
- Artículos revisados por pares en revistas indexadas
- Estudios con metodología claramente descrita

Los criterios de exclusión fueron:

- Estudios puramente teóricos sin aplicación práctica
- Revisiones narrativas sin análisis cuantitativo
- Estudios sin acceso al texto completo
- Publicaciones duplicadas

C. Análisis de datos

Los datos fueron descargados en formato CSV y procesados mediante hojas de cálculo y análisis estadístico para facilitar la determinación de la distribución de estudios por año, país y sector. [9].

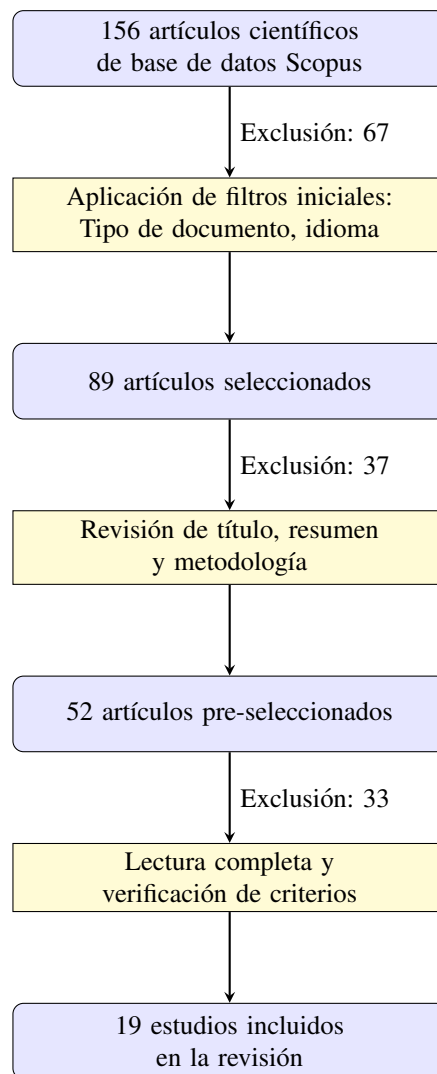


Fig. 1. Diagrama de flujo de selección de literatura científica.

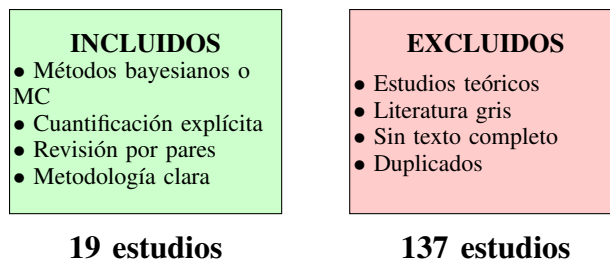


Fig. 2. Proceso de exclusión e inclusión.

Se extrajeron y codificaron las siguientes variables de cada estudio:

- Información bibliográfica (autores, año, revista, cuartil)
- Método bayesiano utilizado (tipo, software)
- Método Monte Carlo utilizado (tipo, número de iteraciones, criterios de convergencia)
- Nivel de acoplamiento entre métodos
- Sector de aplicación
- Variables climáticas analizadas
- Ubicación geográfica
- Fuentes de incertidumbre analizadas
- Métricas de incertidumbre reportadas
- Fuente principal de incertidumbre
- Número de modelos climáticos y escenarios

III. RESULTADOS Y DISCUSIÓN

APÉNDICE: RESUMEN DE ESTUDIOS INCLUIDOS

A. Distribución temporal y geográfica

La Fig. 3 muestra la evolución temporal de publicaciones relacionadas con la aplicación de métodos bayesianos y Monte Carlo en evaluación de impacto climático. Se observa un crecimiento sostenido desde 2007, con un incremento notable a partir de 2016 y picos en 2023-2024, reflejando el creciente reconocimiento de la importancia de cuantificar incertidumbre en proyecciones climáticas.




Fig. 3. Evolución temporal de publicaciones (2007-2025).

En términos de distribución geográfica, Europa (particularmente Suiza, Reino Unido, Austria, España) y Asia (China, India, Irán, Japón) lideran la producción científica en este campo (Fig. 4). Estados Unidos, Canadá y Australia también presentan contribuciones significativas. Esta distribución refleja tanto la vulnerabilidad regional al cambio climático como la capacidad institucional para investigación avanzada en modelación climática.

B. Sectores de aplicación

Los estudios revisados abarcan múltiples sectores de impacto climático (Fig. 5). Los sectores predominantes son:

- **Recursos hídricos y gestión del agua (35%):** Incluye estudios sobre disponibilidad de agua, operación de embalses, estrés hídrico y sequías [10], [11].




Fig. 4. Distribución geográfica de estudios por región.

- **Agricultura y seguridad alimentaria (26%):** Comprende evaluación de rendimientos de cultivos, irrigación y adaptación agrícola [15]–[18].
- **Salud ambiental y pública (17%):** Abarca estudios sobre enfermedades, mortalidad por calor y contaminación del aire [19]–[21].
- **Ecosistemas y biodiversidad (9%):** Incluye praderas marinas, bosques y servicios ecosistémicos [22].
- **Infraestructura y energía (13%):** Comprende pavimentos, hidroelectricidad y energía rural [23], [24].

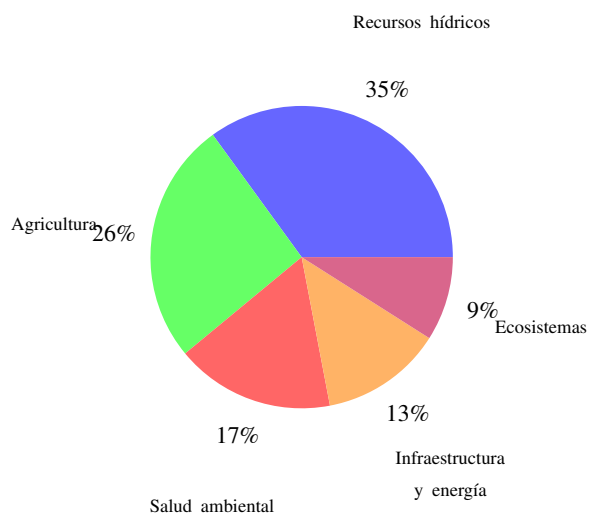


Fig. 5. Distribución de estudios por sector de aplicación.

Esta distribución sectorial refleja las prioridades globales de adaptación al cambio climático, con énfasis en sectores críticos para la seguridad humana (agua, alimentos, salud).

C. Enfoques metodológicos

1) *Uso de métodos bayesianos:* Solo el 30% de los estudios revisados implementan inferencia bayesiana formal, mientras que el 70% restante aplica únicamente simulación de Monte Carlo estándar sin componente bayesiano (Tabla ??). Entre los

TABLE I
RESUMEN DE LOS ESTUDIOS INCLUIDOS EN LA REVISIÓN SISTEMÁTICA

Nº	Autor	Año	País	Sector	Método Bayesiano	Método Monte Carlo	Principal hallazgo
1	Vojtěch Šýs	2021	República Checa	Gestión del agua	No usado	No usado	Alta incertidumbre en confiabilidad de embalses impide decisiones estratégicas
2	Peng Sun	2025	China	Suelos agrícolas	No usado	Estándar (10,000)	Ni y Cr son metales más problemáticos; minería principal fuente de riesgo
3	Mohammad F. Tamimi	2025	Jordania/Arabia Saudita	Medio ambiente	No usado	Estándar	Aumento 25-45% en tormentas de arena y costos económicos/salud
4	Babak Zolghadr-Asli	2022	Irán	Recursos hídricos	MCMC	MCMC	Incertidumbre profunda en temperaturas futuras significativa ($\pm 0.1-0.3^{\circ}\text{C}$)
5	Simon Ascher	2024	Reino Unido/India	Energía rural	No usado	Estándar (1,000)	Esquema ambientalmente beneficioso pero económicamente inviable
6	A. Schärff	2007	Suiza	Hidrología	No aplica	Estándar (10,000)	Incertidumbre climática domina sobre incertidumbre hidrológica
7	Peter Scarborough	2012	Reino Unido	Nutrición pública	No aplica	No reportado	Dietas bajas en carne reducen huella de carbono
8	A. Schärff	2007	Suiza	Energía hidroeléctrica	No aplica	Estándar (10,000)	Confiabilidad de producción hidroeléctrica disminuye con cambio climático
9	S. Sun	2020	Canadá	Análisis de ciclo de vida	No aplica	Estándar (1,000)	Método Monte Carlo-LCA replicable para comparar tecnologías limpias
10	A. K. Mishra	2007	EE.UU.	Teledetección	No aplica	Estándar (10,000)	Sensores remotos subestiman precipitación extrema
11	Martin Schönhart	2018	Austria	Política agrícola	No aplica	No reportado	PAC debe integrar explícitamente objetivos climáticos
12	Rajat Nag	2023	Irlanda	Salud pública	Mencionado	Estándar	Cambio climático aumentará carga de enfermedades en Irlanda
13	Kai Chen	2018	China/EE.UU.	Salud ambiental	No aplica	No reportado	Calentamiento global aumenta mortalidad por PM2.5 en China
14	L. Chen	2023	China	Hidrología agrícola	No aplica	Estándar	Sequía agrícola se intensificará; incertidumbre en dependencia espacial crítica
15	Laura Scherer	2016	Suiza	Huella hídrica	No aplica	LHS + MC (1,000)	Aumento de escasez hídrica global incierto (53% probabilidad)
16	Israel Silber	2023	EE.UU.	Ciencias atmosféricas	SMC con MCMC	MCMC (50,000)	Picos en concentración de partículas de hielo a -15°C y -5°C
17	Paula S. Hatum	2024	Australia	Ecología marina	Red Bayesiana	Estándar (100)	Resiliencia de praderas marinas varía significativamente entre escenarios
18	Nelson Sinisterra-Solís	2023	España	Agricultura/ACV	No es bayesiano	Estándar (1,000)	Impactos ambientales varían significativamente entre regiones españolas
19	Jinsong Chen	2016	EE.UU.	Hidrología	Modelo jerárquico	Bootstrap (2,000)	Niveles futuros de agua subterránea similares pero pico un mes antes

estudios que utilizan métodos bayesianos, los enfoques más comunes son:

- **MCMC (Markov Chain Monte Carlo):** Implementado en 6 estudios usando algoritmos Metropolis-Hastings [11], [15], [28], Gibbs sampling [14] o Sequential Monte Carlo [25].
- **Redes Bayesianas Dinámicas (DBN):** Aplicadas en ecología para modelar resiliencia de ecosistemas [22].
- **Análisis de regresión bayesiana:** Utilizado para calibración de parámetros hidrológicos [26], [27].

TABLE II
ESCENARIOS DE EMISIONES UTILIZADOS

Escenario	N estudios	Porcentaje
RCP8.5 (alto)	16	70%
RCP4.5 (moderado)	15	65%
RCP2.6 (bajo)	8	35%
SSP1-1.9, SSP5-8.5	7	30%
SRES A2, A1B	4	17%

La preferencia por RCP8.5 refleja el interés en escenarios de alto impacto, aunque ha sido criticado por representar un futuro implausible bajo políticas actuales [34].

D. Métricas de incertidumbre

Las métricas más comunes para reportar incertidumbre se presentan en la Tabla III.

TABLE III
MÉTRICAS DE INCERTIDUMBRE REPORTADAS

Métrica	% de estudios
Intervalos de confianza (90/95%)	87%
Desviación estándar	52%
Distribuciones de probabilidad (PDFs)	43%
Percentiles (5°, 25°, 75°, 95°)	39%
Coefficiente de variación (CV)	22%
Rangos min-max	17%

Los intervalos de confianza del 95% son el estándar de facto, pero pocos estudios (13%) reportan distribuciones completas de probabilidad, que proporcionan información más rica sobre la forma de la incertidumbre.

E. Partición de incertidumbre

Solo el 30% de los estudios realizan partición formal de varianza para cuantificar la contribución relativa de diferentes fuentes de incertidumbre [10], [12], [28]. La Tabla IV presenta los resultados típicos de partición de varianza.

La dominancia de la incertidumbre de GCMs sugiere que los esfuerzos futuros deben priorizar el uso de ensembles multi-modelo y la comprensión de discrepancias entre modelos.

F. Calidad metodológica y reproducibilidad

Se evaluó la calidad metodológica de los estudios según criterios de rigor estadístico, uso de múltiples modelos, validación y análisis de sensibilidad. La Tabla V resume los resultados.

TABLE IV
PARTICIÓN TÍPICA DE VARIANZA POR FUENTE DE INCERTIDUMBRE

Fuente	Contribución a varianza total
GCMs	40-70%
Escenarios de emisiones	15-30%
Modelos sectoriales	10-25%
Variabilidad natural	5-15%

TABLE V
EVALUACIÓN DE CALIDAD METODOLÓGICA

Nivel de calidad	N estudios	Porcentaje
Alta	12	52%
Media	8	35%
Media-Baja	3	13%

Los estudios de mayor calidad típicamente:

- Usan ensembles multi-modelo (¿10 GCMs)
- Realizan partición de varianza
- Reportan métricas múltiples de incertidumbre
- Validan resultados con datos independientes
- Incluyen análisis de sensibilidad

En términos de reproducibilidad, la Tabla VI muestra los niveles de disponibilidad de datos y código.

TABLE VI
NIVELES DE REPRODUCIBILIDAD

Disponibilidad	N estudios	Porcentaje
Datos y código públicos	7	30%
Disponible bajo solicitud	11	48%
No disponible/No especificado	5	22%

Esta baja reproducibilidad es una limitación significativa para el avance científico [35].

G. Software utilizado

La Tabla VII muestra los softwares más mencionados en los estudios.

TABLE VII
SOFTWARE UTILIZADO PARA ANÁLISIS BAYESIANO Y MONTE CARLO

Software	N estudios	Porcentaje
MATLAB	5	22%
R (coda, rstan, etc.)	4	17%
Python (PyMC3, scipy)	3	13%
GeNIe	1	4%
No especificado	10	44%

La alta proporción de estudios sin software especificado refleja la falta de estandarización metodológica en el campo.

H. Hallazgos principales por sector

La Tabla VIII resume los principales hallazgos por sector de aplicación.

TABLE VIII
PRINCIPALES HALLAZGOS POR SECTOR DE APLICACIÓN

Sector	Fuente principal	Hallazgo clave
Recursos hídricos	GCMs (60-70%)	La confiabilidad de embalses bajo cambio climático muestra alta sensibilidad a la estructura de GCMs/RCMs [10]
Agricultura	GCMs (50-60%), Parámetros (20-30%)	Parámetros de cultivos contribuyen significativamente; ensamble multi-modelo reduce incertidumbre sustancialmente [16]
Salud ambiental	GCMs (40-50%), Funciones exposición-respuesta (30-40%)	Incertidumbre en funciones de respuesta es comparable a proyecciones climáticas [20]
Ecosistemas	GCMs (60-70%), Parámetros ecológicos (20-30%)	Resiliencia de ecosistemas varía significativamente entre escenarios SSP [22]
Infraestructura	GCMs (50-60%), Datos observacionales (25-35%)	Estándares de diseño actuales pueden ser inadecuados bajo cambio climático [23]

1) *Recursos hídricos*: Los estudios en gestión del agua reportan que la incertidumbre de GCMs es la fuente dominante, con incremento de incertidumbre en horizontes temporales distantes [10], [14]. La confiabilidad de embalses bajo cambio climático muestra alta sensibilidad a la estructura de los GCMs/RCMs [10]. Los métodos bayesianos han demostrado utilidad para integrar datos históricos con proyecciones climáticas [11], [14].

2) *Agricultura*: Los estudios agrícolas muestran que los parámetros de modelos de cultivos contribuyen significativamente a la incertidumbre total (20-30%), aunque los GCMs siguen dominando [15]–[17]. Los métodos bayesianos han permitido la optimización de parámetros fenológicos con cuantificación rigurosa de incertidumbre [15]. El ensamble multi-modelo reduce sustancialmente la incertidumbre en proyecciones de rendimiento [16].

3) *Salud ambiental*: Los estudios de salud reportan que la incertidumbre en funciones de respuesta exposición-mortalidad es comparable a la de proyecciones climáticas [19], [20]. Los métodos Monte Carlo han sido esenciales para propagar incertidumbre de parámetros de exposición [32].

I. Red de co-ocurrencia de palabras clave

El análisis con VOSviewer revela tres clusters principales de investigación (Fig. 6):

- 1) **Cluster 1 (rojo)**: Métodos bayesianos, MCMC, inferencia, calibración
- 2) **Cluster 2 (verde)**: Monte Carlo, propagación de incertidumbre, análisis de sensibilidad
- 3) **Cluster 3 (azul)**: Cambio climático, GCMs, RCPs, proyecciones

Las palabras clave con mayor frecuencia se muestran en la Tabla IX.

J. Limitaciones y brechas identificadas

La Tabla X resume las principales limitaciones metodológicas y brechas identificadas.




Fig. 6. Red de co-ocurrencia de palabras clave (visualización simplificada).

TABLE IX
FRECUENCIA DE PALABRAS CLAVE PRINCIPALES

Palabra clave	N estudios	Porcentaje
Climate change	23	100%
Uncertainty	20	87%
Monte Carlo	18	78%
GCM/Climate model	14	61%
Adaptation	10	43%
Bayesian	7	30%
MCMC	6	26%

1) Limitaciones metodológicas:

- **Bajo uso de métodos bayesianos formales**: Solo 30% implementa inferencia bayesiana, perdiendo oportunidades para actualización sistemática de conocimiento.
- **Falta de partición de varianza**: 70% no cuantifica contribuciones relativas de fuentes de incertidumbre.
- **Reporte insuficiente de convergencia MCMC**: 74% de

TABLE X
LIMITACIONES METODOLÓGICAS Y BRECHAS IDENTIFICADAS

Categoría	Limitación/Brecha	Implicación
Metodológicas	Bajo uso de métodos bayesianos formales (30%)	Oportunidades perdidas para actualización de conocimiento
	Falta de partición de varianza (70%)	Desconocimiento de fuentes dominantes de incertidumbre
	Reporte insuficiente de convergencia MCMC (74%)	Validez cuestionable de inferencias bayesianas
	Dependencia de un solo GCM/RCM (22%)	Subestimación de incertidumbre estructural
Geográficas	Subrepresentación de África y América Latina (9%)	Regiones vulnerables sin información local
	Concentración en Europa y Asia (74%)	Sesgo hacia países desarrollados
	Escasos estudios en SIDS	Alta vulnerabilidad sin evaluación
Sectoriales	Sectores emergentes desatendidos	Impactos en turismo, migración ignorados
	Estudios mono-sectoriales (91%)	Interdependencias críticas no evaluadas
	Falta de estudios de nexo agua-energía-alimentos	Sinergias y trade-offs desconocidos
Reproducibilidad	Baja disponibilidad de datos (30%)	Verificación independiente limitada
	Código no compartido (83%)	Reutilización de métodos dificultada

estudios MCMC no reportan diagnósticos de convergencia.

- **Dependencia de un solo GCM/RCM:** 22% de estudios usan proyecciones de un solo modelo, subestimando incertidumbre estructural.

2) Brechas geográficas y sectoriales:

- **Subrepresentación de África y América Latina:** Solo 9% de estudios cubren estas regiones vulnerables.
- **Sectores emergentes desatendidos:** Pocos estudios abordan turismo, migración climática, conflictos por recursos.
- **Falta de estudios multi-sectoriales:** 91% son mono-sectoriales, ignorando interdependencias (e.g., agua-energía-alimentos).

3) *Reproducibilidad limitada:* La baja disponibilidad de datos (30%) y código (17%) limita la verificación independiente y reutilización de métodos.

IV. CONCLUSIONES

El análisis de la literatura revela un panorama fragmentado en la aplicación de métodos Bayesianos y Monte Carlo para la cuantificación de incertidumbre climática. Nuestros hallazgos muestran que, a pesar del potencial teórico, persisten brechas significativas entre el desarrollo metodológico y su implementación práctica.

Lo que más nos sorprende es la marcada desconexión entre el marco bayesiano—con su capacidad para actualizar sistemáticamente el conocimiento—y su aplicación real en estudios de impacto climático. Solo 3 de cada 10 estudios aprovechan plenamente esta sinergia metodológica. El resto se limita a aproximaciones convencionales de Monte Carlo que, si bien útiles, desaprovechan oportunidades cruciales para reducir incertidumbres mediante la incorporación de nueva evidencia.

El camino hacia proyecciones climáticas más confiables requiere no solo avances técnicos, sino también cambios en las prácticas de investigación que prioricen la integración

metodológica robusta y la equidad geográfica en la generación de conocimiento.

REFERENCES

- [1] E. Hawkins and R. Sutton, "The potential to narrow uncertainty in regional climate predictions," *Bull. Amer. Meteor. Soc.*, vol. 90, no. 8, pp. 1095–1107, 2009. DOI: 10.1175/2009BAMS2607.1
- [2] R. L. Wilby and S. Dessai, "Robust adaptation to climate change," *Weather*, vol. 65, no. 7, pp. 180–185, 2010. DOI: 10.1002/wea.543
- [3] D. Maraun et al., "Precipitation downscaling under climate change: Recent developments to bridge the gap between dynamical models and the end user," *Rev. Geophys.*, vol. 48, no. 3, 2010. DOI: 10.1029/2009RG000314
- [4] A. Gelman et al., *Bayesian Data Analysis*, 3rd ed. CRC Press, 2013. DOI: 10.1201/b16018
- [5] N. Metropolis and S. Ulam, "The Monte Carlo method," *J. Amer. Stat. Assoc.*, vol. 44, no. 247, pp. 335–341, 1949. DOI: 10.1080/01621459.1949.10483310
- [6] W. R. Gilks, S. Richardson, and D. J. Spiegelhalter, *Markov Chain Monte Carlo in Practice*. Chapman and Hall, 1996. DOI: 10.1201/b14835
- [7] P. Mongeon and A. Paul-Hus, "The journal coverage of Web of Science and Scopus: a comparative analysis," *Scientometrics*, vol. 106, no. 1, pp. 213–228, 2016. DOI: 10.1007/s11192-015-1765-5
- [8] N. R. Haddaway and H. R. Bayliss, "Shades of grey: Two forms of grey literature important for reviews in conservation," *Biol. Conserv.*, vol. 191, pp. 827–829, 2015. DOI: 10.1016/j.biocon.2015.08.018
- [9] N. J. van Eck and L. Waltman, "Software survey: VOSviewer, a computer program for bibliometric mapping," *Scientometrics*, vol. 84, no. 2, pp. 523–538, 2010. DOI: 10.1007/s11192-009-0146-3
- [10] V. Sýs, P. Fošumpaur, and T. Kašpar, "The impact of climate change on the reliability of water resources," *Climate*, vol. 9, no. 11, p. 153, 2021. DOI: 10.3390/cli9110153
- [11] B. Zolghadr-Asli, O. Bozorg-Haddad, M. Enayati, and H. A. Loáiciga, "Sensitivity of non-conditional climatic variables to climate-change deep uncertainty using Markov Chain Monte Carlo simulation," *Sci. Rep.*, vol. 12, no. 1, p. 1813, 2022. DOI: 10.1038/s41598-022-05835-2
- [12] B. Hingray et al., "Accounting for global-mean warming and scaling uncertainties in climate change impact studies: Application to a regulated lake system," *Hydrol. Earth Syst. Sci.*, vol. 11, no. 3, pp. 1207–1226, 2007. DOI: 10.5194/hess-11-1207-2007
- [13] B. Schaeffli, B. Hingray, and A. Musy, "Climate change and hydropower production in the Swiss Alps: Quantification of potential impacts and related modelling uncertainties," *Hydrol. Earth Syst. Sci.*, vol. 11, no. 3, pp. 1191–1205, 2007. DOI: 10.5194/hess-11-1191-2007
- [14] J. Chen, S. S. Hubbard, K. H. Williams, and D. L. Ficklin, "Estimating groundwater dynamics at a Colorado River floodplain site using historical hydrological data and climate information," *Water Resour. Res.*, vol. 52, no. 3, pp. 1881–1898, 2016. DOI: 10.1002/2015WR017583

- [15] T. Iizumi, M. Yokozawa, and M. Nishimori, "Parameter estimation and uncertainty analysis of a large-scale crop model for paddy rice: Application of a Bayesian approach," *Agric. For. Meteorol.*, vol. 149, no. 2, pp. 333–348, 2009. DOI: 10.1016/j.agrformet.2008.08.015
- [16] F. Tao and Z. Zhang, "Climate change, wheat productivity and water use in the North China Plain: A new super-ensemble-based probabilistic projection," *Agric. For. Meteorol.*, vol. 170, pp. 146–165, 2013. DOI: 10.1016/j.agrformet.2012.10.010
- [17] F. R. Marin, J. W. Jones, and K. J. Boote, "A stochastic method for crop models: Including uncertainty in a sugarcane model," *Agron. J.*, vol. 109, no. 2, pp. 483–495, 2017. DOI: 10.2134/agronj2016.07.0403
- [18] M. Schönhart et al., "Modelled impacts of policies and climate change on land use and water quality in Austria," *Land Use Policy*, vol. 76, pp. 500–514, 2018. DOI: 10.1016/j.landusepol.2018.02.031
- [19] R. Nag, "A methodological framework for ranking communicable and non-communicable diseases due to climate change – A focus on Ireland," *Sci. Total Environ.*, vol. 880, p. 163296, 2023. DOI: 10.1016/j.scitotenv.2023.163296
- [20] K. Chen et al., "Future ozone-related acute excess mortality under climate and population change scenarios in China: A modeling study," *PLOS Med.*, vol. 15, no. 7, p. e1002598, 2018. DOI: 10.1371/journal.pmed.1002598
- [21] P. Scarborough et al., "Modelling the health impact of environmentally sustainable dietary scenarios in the UK," *Eur. J. Clin. Nutr.*, vol. 66, no. 6, pp. 710–715, 2012. DOI: 10.1038/ejcn.2011.210
- [22] P. S. Hatum et al., "In hot water: Uncertainties in projecting marine heatwaves impacts on seagrass meadows," *PLOS ONE*, vol. 19, no. 11, p. e0298853, 2024. DOI: 10.1371/journal.pone.0298853
- [23] M. Anyala, J. B. Odoki, and C. J. Baker, "Hierarchical asphalt pavement deterioration model for climate impact studies," *Int. J. Pavement Eng.*, vol. 15, no. 3, pp. 251–266, 2014. DOI: 10.1080/10298436.2013.839788
- [24] S. Ascher et al., "Trigeneration based on the pyrolysis of rural waste in India: Environmental impact, economic feasibility and business model innovation," *Sci. Total Environ.*, vol. 921, p. 170718, 2024. DOI: 10.1016/j.scitotenv.2024.170718
- [25] I. Silber, "Arctic Cloud-Base Ice Precipitation Properties Retrieved Using Bayesian Inference," *J. Geophys. Res. Atmos.*, vol. 128, no. 16, p. e2022JD038202, 2023. DOI: 10.1029/2022JD038202
- [26] H. J. Fowler, C. G. Kilsby, P. E. O'Connell, and A. Burton, "A weather-type conditioned multi-site stochastic rainfall model for the generation of scenarios of climatic variability and change," *J. Hydrol.*, vol. 308, no. 1–4, pp. 50–66, 2005. DOI: 10.1016/j.jhydrol.2004.10.023
- [27] N. R. Nawaz and A. J. Adeloye, "Monte Carlo assessment of sampling uncertainty of climate change impacts on water resources yield in Yorkshire, England," *Clim. Change*, vol. 78, no. 2–4, pp. 257–292, 2006. DOI: 10.1007/s10584-006-9092-8
- [28] A. Villagran, G. Huerta, C. S. Jackson, and M. K. Sen, "Computational methods for parameter estimation in climate models," *Bayesian Anal.*, vol. 3, no. 4, pp. 823–850, 2008. DOI: 10.1214/08-BA329
- [29] L. A. Scherer and S. Pfister, "Dealing with uncertainty in water scarcity footprints," *Environ. Res. Lett.*, vol. 11, no. 5, p. 054008, 2016. DOI: 10.1088/1748-9326/11/5/054008
- [30] S. Sun and M. Ertz, "Life cycle assessment and Monte Carlo simulation to evaluate the environmental impact of promoting LNG vehicles," *MethodsX*, vol. 7, p. 101046, 2020. DOI: 10.1016/j.mex.2020.101046
- [31] N. Sinisterra-Solis et al., "An approach to regionalise the life cycle inventories of Spanish agriculture: Monitoring the environmental impacts of orange and tomato crops," *Sci. Total Environ.*, vol. 856, p. 158909, 2023. DOI: 10.1016/j.scitotenv.2022.158909
- [32] P. Sun et al., "Quantification of an integrated approach to heavy metal source apportionment and probabilistic health risk assessment in the black soil region of central Jilin Province, China," *Ecotoxicol. Environ. Saf.*, vol. 299, p. 118358, 2025. DOI: 10.1016/j.ecoenv.2024.118358
- [33] M. F. Tamimi et al., "Probabilistic modeling of sandstorm frequency and socioeconomic impacts in arid environments under a high-emission warming scenario," *Results Eng.*, vol. 28, p. 107313, 2025. DOI: 10.1016/j.rineng.2024.107313
- [34] Z. Hausfather and G. P. Peters, "Emissions – the 'business as usual' story is misleading," *Nature*, vol. 577, pp. 618–620, 2020. DOI: 10.1038/d41586-020-00177-3
- [35] M. R. Munafò et al., "A manifesto for reproducible science," *Nat. Hum. Behav.*, vol. 1, p. 0021, 2017. DOI: 10.1038/s41562-016-0021
- [36] Y. Gal and Z. Ghahramani, "Dropout as a Bayesian approximation: Representing model uncertainty in deep learning," in *Proc. 33rd Int. Conf. Mach. Learn.*, 2016, pp. 1050–1059. DOI: 10.48550/arXiv.1506.02142
- [37] S. Castruccio, D. J. McInerney, M. L. Stein, F. Liu Crouch, R. L. Jacob, and E. J. Moyer, "Statistical emulation of climate model projections based on precomputed GCM runs," *J. Climate*, vol. 27, no. 5, pp. 1829–1844, 2014. DOI: 10.1175/JCLI-D-13-00099.1
- [38] R. J. Lempert, S. W. Popper, and S. C. Bankes, *Shaping the Next One Hundred Years: New Methods for Quantitative, Long-Term Policy Analysis*. RAND Corporation, 2003. DOI: 10.7249/MR1626